

Preface

这一系列的几篇文章(预计 20 篇之内吧)根据 Gilbert Strang 的 Introduction to Linear Algebra 5th Edition 对 Linear Algebra(线性代数) 和 Sheldon Axler 的 Linear Algebra Done Right(3rd Edition) 的一些知识, 以及自身的学习经历进行梳理和复习。书里讲到的知识点, 我会根据自己的知识进行补充, 尽量让它们更加直白容易理解。这些知识对于控制理论的学习是基础性的。我们不要求对每个细节都牢牢记住, 但要求熟悉每一个基本概念。在后续其他学科的学习中, 我们会时常用到 linear algebra 的许多知识, 特别是在线性系统的学习之中, 到时候我们就会发现特意回顾它们的价值。文中会时不时出现中英文的词汇的交替使用, 一来是为了让读者熟悉这些核心概念的英语, 二来是笔者写作的一点习惯。

这里选用了 ElegantBook 作为 Latex 模板写一个短幅的快速复习教程。在此对模板开发团队表示感谢。笔者也不是数学专业出身, 对这门学科的浅薄理解如果有误, 请君不吝指教。转载请联系笔者, 并且注明出处, 谢谢。

邮箱: frankmsj94@gmail.com

三脚猫 Frank
2019 年 12 月 12 日
于 California, USA

第3章 核空间、像空间与秩

Kernel, Image and Rank

3.1 $Ax=b$ 的两种理解

线性代数的核心问题是在于解线性方程组 $Ax=b$, 然而高斯消元法以及一些改良方法, 我觉得应该放到数值计算那里再去细讲。默认读者是第二遍学习, 我这里就跳过基础的解线性方程组的问题了。对于矩阵 A 与向量 x 的相乘, 可以有两种理解方式:

- 等式左边看作是矩阵 A 中列的线性组合。如果 b 在它们所有可能的线性组合之中, 我们就可以找到对应的系数, 那么 x 有解。记 $A = [A_1|A_2|\dots|A_n]$, 其中 A_j 代表 A 的第 j 列, 我们可以写成:

$$x_1 A_1 + x_2 A_2 + \dots + x_n A_n = b \quad (3.1)$$

我们会把 A_j 张成的空间叫列空间 (column space) 或者像空间 (image)。

- 矩阵乘法看作是行与向量之间的 dot product。记 $A = [t_1; t_2; \dots; t_m]$, 其中 t_k 是 A 的第 k 行, 那么我们可以把 $Ax=b$ 写成

$$Ax = \begin{bmatrix} t_1 x \\ t_2 x \\ \vdots \\ t_n x \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix} \quad (3.2)$$

3.2 核空间 Kernel

首先回顾一个矩阵的**核空间 (Kernel)**, 也叫做**零空间 (null space)**。之所以标题叫 Kernel 而不是 null space, 其实是因为我个人在 paper 里见 kernel 的次数比较多, 写起来比较简洁。这完全是个人习惯, 为了让大家不至于忘记它还叫 null space, 我在下文就穿插使用了。

对于上面这个线性方程组, 其完整的解是应该是 $Ax=0$ 的通解与 $Ax=b$ 的特解之和。那么这里使得矩阵 A 满足 $Ax=0$ 的所有 x 向量的集合就是矩阵 A 的 kernel 或者 null space, 我们记为 $\text{Ker}(A)$ 或者 $\text{null}(A)$ 。

我们假设 $x \in \mathbb{R}^n$, 那么我们可以证明 $\text{Ker}(A)$ 是 \mathbb{R}^n 的一个子空间。证明其为 subspace 的过程我们简单叙述: 首先 $\text{Ker}(A)$ 显然是 \mathbb{R}^n 的子集, 其次任何两个 $\text{Ker}(A)$ 上的元素 x, y 之和, $A(x+y)=Ax+Ay=0$, 任然属于 $\text{Ker}(A)$ 。任意一个元素的

scalar multiplication 也同样在 $\text{null}(A)$ 中封闭。于是矩阵的 null space 或者 kernel 就是 \mathbb{R}^n 的一个 subspace。特别的，零向量自身构成了一个零空间，因为任何矩阵与它的乘积都是零向量，并且加法与数乘都是封闭的。

事实上 kernel 和 null space 不光光可以针对矩阵。由于矩阵和线性映射的对应关系，Kernel 和 null space 也可以针对一个 linear map 而言。我们在这里把矩阵替换成 T 之后就可以同样定义一遍。回顾在映射的概念中，什么叫做单射 (injective)。一个映射是 injective 的，即满足 $f(x) = f(y) \rightarrow x = y$ 。考虑一个 n 维实向量空间 V 和一个 m 维实向量空间 W ，有一个 linear map 记作 $T: V \rightarrow W$ ，如果 T 是单射的，那么由于 $T(0)=0$ ，零向量就是满足 $Tx=0$ 唯一的向量。同理 $Ax=0$ ，如果 $x=0$ 是唯一的解，那么我们必然知道 A 的各列是线性独立或者线性无关的。反过来，如果 A 的各列是 linear independent 的，那么 A 的 Kernel 或者 null space 就是 trivial 的，即由单一的零元素组成的。

Kernel 这个名字其实也很形象，就是 V 中的元素在 T 或者 A 的作用下，压缩到了原点，就像一个核一样。如果不巧，一个 basis 中的向量被压缩到了原点，那么其像空间的维度就会相应减少，我们下面会详细展开这个讨论。直观上我们能感觉到 Kernel 的维度如果变高了，说明更多信息都被压缩了。这就是说在 T 的作用下原空间降维了。

3.3 像空间 Image

一个 m -by- n 的矩阵 A 的像空间 (Image) 也被称为列空间 (column space)，记为 $\text{Im}(A)$ 。同理我们也可以对映射进行类似定义，对映射定义时像空间也叫 range，记为 $\text{range}(T)$ 。 $\text{Im}(A)$ 是 A 的所有列张成的空间，即所有列的线性组合构成的空间。它同样是一个子空间，但是却是 \mathbb{R}^m 的子空间。这一点我们同样要通过子空间的定义去证明。另外如果 T 是满射的 (surjective)，那么 T 的像空间就是 W 。换做是矩阵，意味这其列向量张成了 \mathbb{R}^m 空间。

3.4 秩

秩 (rank) 的概念我们一定不陌生。一个矩阵的行秩是行张成空间的维度，列秩是列张成的维度。关于秩我们回顾两个重要的定理：

定理 3.1

行秩与列秩相等



于是我们可以把行秩和列秩统一称为 rank，一般可以计算列秩。



定理 3.2

A 是一个 m -by- n 的矩阵, 那么 $\text{rank}(A) = \text{Dim}(\text{Im}(A))$



上面的定理告诉我们一个矩阵的列秩是列空间或者像空间的维度。这很好理解, 本来我们定义像空间就是由矩阵的所有列张成的。那么列秩代表了列的最大的线性无关组中包含的列数, 也就是像空间最小 spanning list 的长度。

3.5 线性映射基本定理

线性映射基本定理, 也叫秩-零化度定理 (rank-nullity theorem)。我这里采用线性映射的说法, 再用矩阵去解释。我们不完整证明它, 只说说它的直观理解。

定理 3.3

V 是一个有限维空间, T 是一个从 V 到另一个向量空间 W 的线性映射。那么 T 的像空间是一个有限维空间, 并且

$$\dim V = \dim \text{null}(T) + \dim \text{range}(T) \quad (3.3)$$



这里定理说 V 的维度就是 T 零空间的维度与像空间维度之和。我们从最简单的情况分析一下是不是对的。

3.5.1 null space 只有零向量

首先一个线性映射 T 的 null space 可以分为两种情况, 只有 0 或者还存在非 0 向量。我们之前说过 T 单射时, null space 只有 0 向量, 此时由于只有 0 向量, 它自身线性相关, 于是没有 basis, 维度为 0。此时我们考虑 V 上的一组基, 在 T 的作用下, 这组基的像 Tv_j 是落到了像空间 $\text{range}(T)$ 中的, 并且不在 null space 中 (0 向量是唯一解), 那么我们证明一下这组基的像仍然是线性独立的, 并且上面基本定理成立。

证明 已知 T 的 null space 中只有 0 向量, 则 $\dim \text{null}(T) = 0$ 。现取 (v_1, v_2, \dots, v_n) 是 V 中的一组基, 那么一定有:

$$c_1 v_1 + c_2 v_2 + \dots + c_n v_n = 0 \quad (3.4)$$

当且仅当 c_j 同时为 0。现在对上式做 T 变换

$$T(c_1 v_1 + c_2 v_2 + \dots + c_n v_n) = 0 \quad (3.5)$$

$$c_1 T v_1 + c_2 T v_2 + \dots + c_n T v_n = 0 \quad (3.6)$$



由于 $Tv_j \neq 0$ (v_j 不在 null space 中), 所以得到这 n 个 Tv_j 线性独立。因为所有 V 中的向量都可以由 (v_1, v_2, \dots, v_n) 表示, 像空间中的向量:

$$Tv = T(b_1v_1 + b_2v_2 + \dots + b_nv_n) \quad (3.7)$$

$$= b_1Tv_1 + b_2Tv_2 + \dots + b_nTv_n \quad (3.8)$$

所有像都可以由 Tv_j 来表示, 于是我们肯定像空间的维度为 n 。即有 $\dim V = 0 + n = n$ \square

我们从上面的证明中可以看到, 如果有一个 T , 它的 null space 中只有一个零元素, 那么原空间中的基也就可以仍然通过线性映射转化到像空间中, 成为像空间的基。这时候我们发现在这种 T 的作用下, 原空间与像空间的维度没有发生变化!

3.5.2 null space 还有非零向量

现在假设有一个线性映射 T , 它的 null space 不再只有一个零向量了, 假设里面还有许多非零向量。¹, 但是我们不确定维数。没有关系, 我们假设 null space 其中一个非零向量 v^* , 我们知道有一组不全为 0 的系数 a_j 使得²:

$$Tv^* = 0 \quad (3.9)$$

$$T(a_1v_1 + a_2v_2 + \dots + a_nv_n) = 0 \quad (3.10)$$

$$a_1Tv_1 + a_2Tv_2 + \dots + a_nTv_n = 0 \quad (3.11)$$

a_j 不全为 0, 那么我们就知道 Tv_j 必然不是线性独立的。即像空间的维度一定会小于 n 。我们现在假设 a_j 中最多只有一个不为 0, 比如 $a_1 \neq 0$, 其他系数必须满足 $a_2 = \dots = a_n = 0$, 则可以得到

$$a_1Tv_1 = 0, a_1 \neq 0$$

$$a_2Tv_2 + \dots + a_nTv_n = 0, a_2 = \dots = a_n = 0$$

那么我们推知 $\{Tv_2, \dots, Tv_n\}$ 线性独立, 并且

$$Tv_1 = 0$$

即我们选择的一组基中的向量 v_1 是属于这个 null space 的, v_1 这个基中的向量被压缩到了 kernel 里了! 那么此时像空间中的元素怎么表示呢?

$$Tv = T(b_1v_1 + b_2v_2 + \dots + b_nv_n) \quad (3.12)$$

$$= b_1Tv_1 + b_2Tv_2 + \dots + b_nTv_n \quad (3.13)$$

$$= b_2Tv_2 + \dots + b_nTv_n \quad (3.14)$$

¹因为向量可以缩放, 所以实际上 null space 里的元素要么只有一个, 要么就是无穷多个

²因为 v^* 是非零向量

由于 v_1 被压缩为零向量了，我们发现所有像空间的元素都可以由 $\{Tv_2, \dots, Tv_n\}$ 表示，并且由于它们线性独立，所以**像空间的维度** $\dim \text{range}(T) = n - 1$ 。

那么对应 null space 的维度呢？由于我们假设只有 $a_1 \neq 0$ ，实际上此时，任何一个 null space 中的非零元素必然满足那么 $v^* = a_1 v_1$ 。所以此时 null space 的上线性独立的向量就只有 v_1 或者与它成正比的向量³。我们直接取 v_1 作为基，那么显然有 $\dim \text{null}(T) = 1$ 。于是 $\dim V = \dim \text{null}(T) + \dim \text{range}(T) = 1 + (n - 1) = n$ 。定理结论再次得到证实。

我们可以在上面的过程中任意选择几个 a_j 不为 0，而其他系数全为 0，则我们会对应产生 2 维的 null space， $n-2$ 维的像空间。依次类推，如果 T 这个线性映射是个零映射，那么所有的元素都被压缩到了 kernel 里，null space 就是 n 维，对应的像空间就变成了 0 维。所以我们发现零空间与像空间的维度在 T 的作用下是一个**此消彼长的过程**：像空间的维度会随着零空间的维度的增大而减小。

3.5.3 矩阵表述

上面所有的结论我们都可以用矩阵来重新表述一遍。定义零化度 (Nullity) $\text{Nullity}(A) = \dim \ker(A)$ 首先定理可以表述为

定理 3.4. rank-nullity theorem

V 是一个有限维空间， T 是一个从 V 到另一个向量空间 W 的线性映射。 A 是由 T ，以及 V 和 W 的一组基确定的矩阵。那么 $\text{Im}(A)$ 是一个有限维空间，并且

$$\dim V = \text{Nullity}(A) + \text{Rank}(A) \quad (3.15)$$

意思还是一样的，矩阵 A 的 null space 维度与 column space 的维度之和为 V 的维度。回忆 T 对应的矩阵的定义方式，矩阵的第 k 列就是

$$Tv_k = c_1 w_1 + c_2 w_2 + \dots + c_m w_m \quad (3.16)$$

如果矩阵的零空间中只有零向量，说明各列是线性独立的，那么 Tv_k 也就是线性独立的，故而列秩为 n ，像空间维度为 n 。如果有非零向量，则各列线性相关，我们选择踢出相关的列，这些列对应的基向量 $v_{i_1}, v_{i_2} \dots v_{i_p}$ 就被压缩到了零空间，于是产生了 $n-p$ 维的零空间。剩下的 p 列线性独立向量，张成了 p 维像空间。

3.6 几个推论

我们来看看上面的定理能够推理得到什么。

³这里表达的意思是向量可以比例伸缩

命题 3.1

如果 W 的维度比 V 小，那么 T 不可能是一个单射。

如果 W 的维度比 V 小，那意味着 T 把原来的 V 空间降维了，由此我们知道对应的零空间必然有非零向量，因此 Kernel 的维度必然大于等于 1。由于线性映射已经满足 $T(0)=0$ ，必然存在另外一个非零向量满足 $Tv=0$ 。于是它必然不是一个单射。我们把这个推论用到齐次方程组上正好可以得到下面的结论：

命题 3.2

一个线性齐次方程组的变量个数大于方程数，则存在非零解。

把整个方程组看作 $Ax=0$ 的话, $x \in R^n$ 。我们知道变量个数 n 代表了 A 矩阵的列数，并且我们假设变量之间都是相互独立，这 n 个变量张成了一个 n 维向量空间。方程的行数 m 代表了像 Ax 所处的空间的最高维度，假如 A 矩阵的行也是线性无关的，那么矩阵 A 就把 x 从 R^n 空间映射到了 R^m 上。我们现在知道 $n > m$ ，而且 $\text{rank}(A) = \dim(\text{Im}(A)) \leq m^4$ ，所以根据上面的定理，我们有 $\text{Nullity}(A)=n-\text{rank}(A)>0$ 。这样 A 所代表的映射必然不是单射，意味着 $Ax=0$ 有非零解。

命题 3.3

如果 W 的维度比 V 大，那么 T 不可能是一个满射。

T 的像空间是 W 的子空间，最大的维度也就是 V 的维度了。如果 V 的维度都比 W 小，那么 $\text{Im}(T)$ 一定不会等于 W ，故而不会是满射，其维度一定比 W 低。

命题 3.4

一个线性非齐次方程组的变量个数小于方程数，则可能无解。

对于 $Ax=b$ 的解我们之前也说了，如果 $\text{Im}(A)$ 的维度比 W 小，那么我们可以找到一个 $b \in W$ ，且不在 $\text{Im}(A)$ 中，那么 $Ax=b$ 自然无解。如果运气好的话， b 也在 $\text{Im}(A)$ 中，那么仍然有解。

重点

- $Ax=b$ 的两种理解
- 核空间与像空间的定义
- 秩的回顾
- 线性映射基本定理的理解

⁴因为 $\text{Im}(A)$ 是 R^m

Reference

- 全文参考了 Sheldon Axler 的 Linear Algebra Done Right(3rd Edition) 第三章 3B
- 关于秩-零化度定理的直观解释，参考了 stack exchange 的一个[回答](#)。我把比较完整的一个思路用数学语言给补全了。